

programa de pós-graduação em
ENGENHARIA DE DEFESA

Álgebra Linear Computacional

Parte VI

Maj Hebert **AZEVEDO** Sá, Ph.D.

Definições Básicas

Definição: Seja A uma matriz $n \times n$. Um autovalor de A será um escalar λ e seu autovetor associado será um vetor v , tais que:

$$Av = \lambda v \implies (A - \lambda I)v = 0.$$

Naturalmente, para que a solução seja diferente da trivial, é necessário que $\det(A - \lambda I) = 0$. O resultado dessa equação é um polinômio de grau n dado por

$$\det(A - \lambda I) = p(\lambda) = a_n \lambda^n + a_{n-1} \lambda^{n-1} + \cdots + a_1 \lambda + a_0,$$

chamado ***polinômio característico*** de A . As raízes de $p(\lambda)$ serão, portanto, os autovalores de A . Cada λ distinto tem um v associado, de forma que v e Av são **colineares**.

Exemplo [Ford, Exemplo 5.1]

Exemplo [Ford, Exemplo 5.2]

Exemplo [Ford, Exemplo 5.5]

As seguintes propriedades são válidas:

- $A_{n \times n}$ é singular $\iff 0$ é autovalor de A
- Os autovetores de uma matriz A formam um subespaço vetorial chamado *autoespaço* de A .
- $\det(A_{n \times n}) = \lambda_1 \cdot \lambda_2 \cdot \dots \cdot \lambda_n$

No numpy, o cálculo de autovalores e autovetores é realizado com `numpy.linalg.eig` e outras funções semelhantes.

Exemplo:

```
1  import numpy.linalg as la
2
3
4  A = [[4, 8, 3],
5       [0, -1, 0],
6       [0, -2, 2]]
7
8  E = la.eig(A)
9
10 print(E)
```

Definição: A e B são matrizes *similares* se existe uma matriz X tal que $B = X^{-1}AX$.

Definição: Uma matriz $n \times n$ é diagonalizável se for similar a uma matriz diagonal.

Teorema: Duas matrizes similares possuem os mesmos autovalores.

Teorema: Autovalores distintos estão associados a autovetores linearmente independentes.

Diagonalização

Teorema: Seja uma matriz $A_{n \times n}$ possuindo n autovetores linearmente independentes $v_1, v_2, \dots, v_n$. Seja também a matriz X formada por colunas iguais a v_i , i.e., $X = [v_1 \ v_2 \ \dots \ v_n]$. Então, teremos

$$D = X^{-1}AX = \begin{bmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 \\ \dots & \dots & \dots & \dots \\ 0 & 0 & \dots & \lambda_n \end{bmatrix},$$

e A será diagonalizável. Além disso, $A = XDX^{-1}$ e $A^n = XD^nX^{-1}$

Finalmente, como autovalores distintos implicam em autovetores L.I., podemos concluir que se A possui n autovalores distintos, A será diagonalizável.

Definição: Uma função $\|\cdot\| : \mathcal{X} \rightarrow \mathcal{F}$ (em geral consideraremos $\mathcal{F} = \mathbb{R}$) será uma **norma** se satisfizer as seguintes condições:

- $\|x\| \geq 0, \forall x \in \mathcal{X}$
- $\|x\| = 0 \iff x = 0$
- $\|x + y\| \leq \|x\| + \|y\|$
- $\|\alpha x\| = |\alpha| \|x\|, \forall x \in \mathcal{X}, \alpha \in \mathcal{F}$

A norma Euclidiana é a mais óbvia e comum. É definida por $\|x\|_2 = \sqrt{\sum_{i=1}^n |x_i|^2}$.


A norma p é uma generalização da Euclidiana, dada por $\|x\|_p = \sqrt[p]{\sum_{i=1}^n |x_i|^p}$.

Um espaço vetorial com uma norma permite a definição de **distância** entre dois pontos.

Espaços Vetoriais com Normas

Casos especiais da norma p :

- $p = 1$: norma “Manhattan”, dada por $\|x\|_1 = \sum_{i=1}^n |x_i|$
- $p = 2$: norma Euclidiana
- $p \rightarrow \infty$: norma “Máxima”, dada por $\lim_{p \rightarrow \infty} \|x\|_p = \max_{i=1,2,\dots,n} |x_i|$



Espaços Vetoriais com Normas

Exemplo de código para gerar a figura que representa o LG dos pontos em que a norma p é unitária em 2-D :

```
import matplotlib.pyplot as plt
import numpy as np

p = 1

x = np.arange(0.0, 1.001, 0.001)

y = np.power((1 - np.power(x, p)), 1/p)

fig, ax = plt.subplots()

# Plots de cada ramo
ax.plot( x, y, 'b')
ax.plot( x, -y, 'b')
ax.plot(-x, y, 'b')
ax.plot(-x, -y, 'b')

ax.axis('equal')
ax.grid()

title_string = f"LG para norma p unitária (p = {p})"

ax.set(xlabel='x', ylabel='y', title=title_string)

plt.show()
```

Definição: Seja um espaço vetorial sobre o campo complexo $(\mathcal{X}, \mathbb{C})$. Uma função $\langle \cdot, \cdot \rangle: \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{C}$ será considerada um **produto interno** se:

- $\langle x_1, x_2 \rangle = \overline{\langle x_2, x_1 \rangle}$
- $\langle \alpha_1 x_1 + \alpha_2 x_2, x_3 \rangle = \alpha_1 \langle x_1, x_3 \rangle + \alpha_2 \langle x_2, x_3 \rangle$
- $\langle x, x \rangle \geq 0, \quad \forall x \in \mathcal{X}$
- $\langle x, x \rangle = 0 \iff x = 0$

Se o campo escalar for resumido ao campo real, basta substituírmos a primeira condição por $\langle x_1, x_2 \rangle = \langle x_2, x_1 \rangle$

Exemplos:

- $(\mathbb{C}^n, \mathbb{C}), \langle x, y \rangle = x^\top \bar{y}$
- $(\mathbb{R}^n, \mathbb{R}), \langle x, y \rangle = x^\top y$
- $(\mathbb{R}^3, \mathbb{R})$ ou $(\mathbb{R}^2, \mathbb{R}), \langle x, y \rangle = x^\top y = \|x\| \|y\| \cos \theta$ (produto escalar)
- $\mathcal{X} = \{f : [a, b] \rightarrow \mathbb{R} \mid f \text{ é contínua}\}, \mathcal{F} = \mathbb{R}, \langle f, g \rangle = \int_a^b f(t)g(t)dt$

Teorema [Desigualdade de Cauchy-Schwarz]: Seja um espaço vetorial $\mathcal{X}$ sobre o campo escalar complexo ou real com produto interno. Para todo $x, y \in \mathcal{X}$ teremos

$$| \langle x, y \rangle | \leq \sqrt{\langle x, x \rangle \langle y, y \rangle}$$

Espaços Vetoriais com Produto Interno

O caso particular mais comum de produto interno é o produto escalar entre dois vetores $x, y \in \mathbb{R}^n$, dado por

$$\langle x, y \rangle = x^\top y = x_1 y_1 + x_2 y_2 + \cdots + x_n y_n$$

É possível encontrar o ângulo entre dois vetores no $\mathbb{R}^n$, mesmo que sua representação geométrica seja totalmente abstrata:

$$\theta = \arccos\left(\frac{\langle x, y \rangle}{\sqrt{\langle x, x \rangle \langle y, y \rangle}}\right), \quad 0 \leq \theta \leq \pi$$

Naturalmente há casos especiais em que $\theta = 0, \frac{\pi}{2}, \pi$. O que significam?

Quando $\langle x, y \rangle = 0$, temos $\theta = \frac{\pi}{2}$. Nesse caso, os vetores x e y são chamados ortogonais entre si.

No caso especial em que x e y possuem norma unitária, os vetores são chamados ortonormais.

Um conjunto de k vetores ortogonais será L.I. e, por consequência, será uma base de um subespaço k -dimensional. Se os k vetores forem ortonormais, a base será chamada ortonormal.

Vetores e Matrizes Ortogonais

Uma matriz P cujas colunas sejam vetores ortonormais entre si é chamada de **matriz ortogonal**. Nesse caso, $P^{-1} = P^T \implies P^T P = I$.

Matrizes ortogonais possuem determinante ± 1 .

Matrizes reais simétricas são diagonalizáveis com uso de matrizes ortogonais, i.e., seus autovetores são ortogonais entre si e podem ser normalizados para comprimento 1

Matrizes ortogonais representam transformações lineares invariantes com respeito à norma Euclideana, i.e., não alteram a norma 2 dos vetores. Com efeito,

$$\|Px\|_2^2 = (Px)^T Px = x^T P^T Px = x^T x = \|x\|_2^2 \implies \|Px\|_2 = \|x\|_2.$$

Norma de uma Matriz

Normas de matrizes são formas de “medir o tamanho” de uma matriz, e são importantes para avaliarmos o condicionamento de sistemas lineares. A definição geral e as condições a serem satisfeitas por uma norma em um espaço vetorial podem ser usadas para definirmos normas de matrizes.

São exemplos de normas de matrizes:

- Norma de Frobenius: $\|A\|_F = \left(\sum_{i=1}^m \sum_{j=1}^n a_{ij}^2 \right)^{\frac{1}{2}}$
- Norma p induzida: $\|A\|_p = \max_{x \neq 0} \frac{\|Ax\|_p}{\|x\|_p}$

Uma norma é chamada *submultiplicativa* se, para matrizes $A, B \in \mathbb{R}^{n \times n}$,

$$\|AB\| \leq \|A\| \|B\|$$

Norma (2) de uma Matriz

Exemplo: Calcular a norma 2 induzida da matriz $\begin{bmatrix} 1 & -8 \\ -1 & 3 \end{bmatrix}$.

Precisamos encontrar o valor $\|A\|_2 = \max_{x \neq 0} \frac{\|Ax\|_2}{\|x\|_2}$.

Uma forma de simplificar esse cálculo é restringir x a um círculo unitário (esfera para $\mathbb{R}^3$ ou n -esfera para $\mathbb{R}^n$). Daí, teremos

$$\|A\|_2 = \max_{\|x\|_2=1} \|Ax\|_2$$

Em duas dimensões, esse problema torna-se uma otimização não linear a uma variável.

Norma (2) de uma Matriz

Exemplo de código para estimativa de solução:

```
import numpy as np

A = np.array([[1, -8], [-1, 3]])

n = 1000

theta_0 = 0
theta_f = 2 * np.pi
dtheta = (theta_f - theta_0)/n

lengths = []
for i in range(n+1):
    x = np.array([np.cos(theta_0 + i*dtheta), np.sin(theta_0 + i*dtheta)])
    y = A @ x
    lengths.append(np.linalg.norm(y))

m = max(lengths)
```

Teorema [Ford, Theorem 7.7]: A norma 2 induzida de uma matriz A será a maior entre as raízes quadradas dos autovalores da matriz $A^T A$. Isto é,

$$\|A\|_2 = \max_{\|x\|_2=1} \|Ax\|_2 = \max \sqrt{s_i},$$

onde s_i são os autovalores de $A^T A$. As raízes dos autovalores de $A^T A$, i.e., $\sqrt{s_i} = \sigma_i$ são chamadas de valores singulares de A . Veremos isso com mais detalhes quando falarmos de Decomposição por Valores Singulares (SVD).

Propriedades da Norma 2 de uma matriz:

- Para quaisquer matrizes ortogonais U e V , $\|UAV\|_2 = \|A\|_2$
- o *raio espectral* de uma matriz real $A_{n \times n}$ será o máximo dentre os valores absolutos de seus autovalores, i.e., $\rho(A) = \max_{1 \leq i \leq n} |\lambda_i|$
- Se $A_{n \times n}$ é simétrica, $\|A\|_2 = \rho(A)$; além disso, seus valores singulares são os valores absolutos de seus autovalores
- $\|A\|_2 = \|A^T\|_2$
- $\|A^T A\|_2 = \|A A^T\|_2 = \|A\|_2^2$
- $\|A^{-1}\|_2 = \frac{1}{\sigma_{min}}$, onde σ_{min} é o menor valor singular de A